

条款

基于自适应双遗忘因子的Sage-Husa算法

李文娟^{1,*}, 詹明静²和冯慧³

¹ 江苏科技大学海洋装备与技术研究所, 镇江 212003, 中国

² 江苏科技大学船舶与海洋工程学院, 镇江 212003, 中国

³ 教育部高性能船舶技术重点实验室, 武汉理工大学, 中国武汉430063

* 通信: wenjuanli03211017@126.com

摘要: 针对Sage-Husa算法在非线性系统状态估计中存在滤波精度不足和滤波发散等问题, 本文提出了一种基于自适应双遗忘因子的改进算法。该算法在原有Sage-Husa算法的基础上, 通过引入双遗忘因子并结合指数形式的窗口化方法进行自适应调整。在确保过程噪声协方差矩阵半正定性和观测噪声协方差矩阵正定性的前提下, 采用协方差匹配技术判断测量噪声统计特性是否需要更新。仿真结果表明, 该算法显著提升了滤波精度, 展现出强大的实用性和可行性。

关键词: 非线性系统; Sage-Husa; 自适应双遗忘因子; 窗函数; 指数形式

1. 介绍

卡尔曼滤波是一种广泛应用于动态系统状态估计的递归算法[1, 2]。然而, 其适用性仅限于线性系统。对于非线性系统, 通常采用扩展卡尔曼滤波(EKF)[3–5]、无香卡尔曼滤波(UKF)[6–8]和粒子滤波(PF)[9–11]等替代方法。其中, EKF在精度与实时性能之间提供了良好的平衡, 使其成为实际应用中极具前景的方法。

在状态估计的EKF应用中, 通常假设过程噪声和测量噪声的统计特性是已知且恒定的。然而在实际应用中, 由于运行环境的可变性和不可预测性, 噪声参数往往表现出不确定性。这种不确定性会显著降低滤波精度, 甚至可能导致滤波器发散。为解决这一挑战, 已提出多种自适应滤波技术, 包括最大似然法[12, 13]、强跟踪滤波器[14, 15]、基于人工智能的方法[16, 17], 以及基于最大后验准则的Sage-Husa算法[18]。其中, Sage-Husa算法凭借其简洁性和计算效率, 已成为自适应滤波研究领域的领先方法, 并被广泛研究和应用。

理论上, 传统的Sage-Husa算法能够同时更新过程噪声与测量噪声的统计特性。然而, 在实际应用中



接收日期: 2024年10月8日

修订日期: 2024年12月20日

接受日期: 2025年1月16日

发布日期: 2025年2月8日

引用: Li, W.; Zhan, M.; Feng, H.

基于自适应双遗忘因子的Sage-Husa算法。应用科学 2025, 15, 1731。

<https://doi.org/10.3390/app15041731>

版权所有: © 2025 作者。

被许可方 MDPI, 瑞士巴塞尔。

本文是一篇开放获取文章, 根据知识共享署名 (CCBY) 许可协议

(<https://creativecommons.org/licenses/by/4.0/>) 的条款和条件发布。

在卡尔应用中，同时估计过程噪声和测量噪声具有显著挑战性，常导致过程噪声失去半正定性、测量噪声失去定性等问题。此外，在高阶系统中，滤波器发散现象频繁出现。为解决上述问题，学界已开展大量研究以探索Sage-Husa算法的多种改进方案。Jiang等人[19]采用简化的Sage-Husa估计器实现在线测量噪声协方差矩阵，该方法基于具有速度预测的自适应电流统计模型。Wang等人[20]采用改进算法仅用于估计测量噪声，其中预测误差协方差矩阵的负部分被移除，因其可能导致滤波器发散，从而确保测量噪声的正定性。Wang等人[21]采用模糊逻辑控制方法实现简化Sage-Husa滤波器参数遗忘因子的自适应调整。该Sage-Husa自适应滤波器基于协方差匹配技术进行更新，该技术已应用于平移式喷灌机的导航[22]。Sun等人[23]将估计器的滤波收敛准则引入Sage-Husa自适应卡尔曼滤波器中，该准则被应用于实时滤除雾天随机漂移误差，有效降低了雾天误差并提高了其精度。Fan等人[24]提出了一种改进的基于强跟踪的扩展Sage-Husa自适应鲁棒卡尔曼滤波算法，该算法结合了强跟踪KF和Sage-Husa鲁棒自适应KF，以降低由波浪和船舶振荡引起的瞬态干扰的影响。Wang等人[25]引入了一种新型加权调整系数，并从协方差匹配的角度自适应调整了过程噪声和观测噪声，从而提高了FSI系统的精度。Xu等人[26]提出了一种联邦Sage-Husa自适应滤波器，该方法以联邦滤波器作为多源集成导航的框架，而本地滤波器则采用改进的Sage-Husa自适应滤波器。Qiao等人[27]提出了一种新颖的平方根分解方法，将其应用于Sage-Husa卡尔曼滤波算法中，以分解协方差矩阵，确保其非负定性，并引入自适应缩放因子来更新卡尔曼增益和状态估计误差协方差。

针对Sage-Husa算法改进的研究已证实其过滤性能有所提升。然而，目前鲜有研究对算法中遗忘因子的作用进行全面探讨。在传统含遗忘因子的Sage-Husa算法中，遗忘因子的取值通常基于经验确定，且一般仅采用单一数值。但固定单一的遗忘因子往往缺乏适应性，难以有效应对动态系统环境变化。Wei等人[28]该研究提出双遗忘因子法作为单遗忘因子法的扩展，分别采用两个独立因子分别更新测量噪声和系统状态噪声。然而，由于两个遗忘因子均为固定值，其适应系统动态变化的能力受到限制。Guo等人[29]还提出了双遗忘因子的概念。两个遗忘因子分别用于更新过程噪声和测量噪声的统计特性，但未提供这两个遗忘因子的具体数值设定方法。Xiang等人[30]采用有限记忆指数加权法和渐近记忆指数加权法两种遗忘因子，分别对应测量噪声的快慢变化程度及过程噪声的统计特性。其中两个遗忘因子为固定值。文献[31]提出改进版Sage-Husa自适应滤波算法，通过动态调整遗忘因子实现参数优化，尽管相关参数仍采用经验确定。该算法基于指数函数进行变换，以拟合动态遗忘因子[32]。为增强对时变噪声系统动态变化的适应能力，引入了可变自适应遗忘因子

该因子的设计基于创新方差总和与创新协方差估计矩阵迹的比值，随后被整合到Sage-Husa算法[33]中。Sage-Husa算法中可变遗忘因子的应用相对有限，但可变遗忘因子方法已在递归最小二乘（RLS）算法中得到广泛应用。Leung等人[34]提出了一种基于梯度的可变遗忘因子控制机制。该机制的核心在于利用均方误差的动态方程，推导出均方误差梯度的动态方程，进而实现对遗忘因子的精准调控。Wang等人[35]采用模拟退火算法实现遗忘因子的动态调整，但计算过程相对复杂。Xie等人[36]提出了可变遗忘因子的概念，通过动态调整其权重来适应系统的动态变化。然而，具体权重选择方法并未得到明确说明。研究者以模型识别值与实际值之间的残差为变量，开发了多种校正公式（如反正切模型或指数模型），从而实现了遗忘因子的动态调整[37–41]。基于双遗忘因子理论，研究者将自适应双遗忘因子引入Sage-Husa算法，实现了对遗忘因子的动态调节。

本文提出的方法以Sage-Husa算法为基础框架。首先，确保测量噪声协方差矩阵的正定性及系统状态噪声协方差矩阵的半正定性。其次，引入双遗忘因子，采用滑动窗口法获取先验与后验残差。通过指数形式自适应更新遗忘因子，确保其稳定在0.95至1的范围内。最后，基于先验残差与理论残差的对比结果，决定是否更新测量噪声的统计特性。仿真结果表明，所提出的改进算法具有显著的实用性和可行性。

本文的其余部分安排如下：第2节详细描述自适应Sage-Husa滤波算法。第3节提供仿真结果和讨论。结论在第4节中描述。

2. 自适应Sage-Husa滤波算法

2.1. 带遗忘因子的Sage-Husa算法

考虑以下非线性系统：

$$X_k = f(X_{k-1}, U_{k-1}) + W_{k-1} \quad (1)$$

$$Z_k = h(X_k, U_k) + V_k, \quad (2)$$

其中 X_k 是系统的 n 维状态向量； Z_k 是 m 维测量向量； f 和 h 分别是状态转移函数和测量函数； u_k 是系统的输入变量。 W_{k-1} 和 V_k 被假设为不相关的零均值高斯白噪声，其协方差分别为 Q_{k-1} 和 R_k ，表示为 $E(W_{k-1}) = E(V_k) = 0$ ， $E(W_{k-1} W_{k-1}^T) = Q_{k-1}$ ， $E(V_k V_k^T) = R_k$ ，且 $E(W_{k-1} V_k^T) = 0$ 。

Sage与Husa联合提出的Sage-Husa算法，可在线估计测量噪声协方差矩阵和过程噪声协方差矩阵。该算法基于最新测量更新信息，能够估计测量噪声与过程噪声的统计特性，从而实现滤波器的优化。非线性系统的Sage-Husa算法可表述为：

$$P_{k|k-1} = \Phi_{k-1} P_{k-1|k-1} \Phi_{k-1}^T + Q_{k-1}, \quad (3)$$

$$\hat{X}_{k|k-1} = f(\hat{X}_{k-1|k-1}, U_{k-1}), \quad (4)$$

$$e_k = Z_k - h(\hat{X}_{k|k-1}), \quad (5)$$

$$R_k = (1 - dk) R_{k-1} + dk (e_k e_k^T - H_k P_{k|k-1} H_k^T), \quad (6)$$

$$K_k = P_{k|k-1} H_k^T (H_k P_{k|k-1} H_k^T + R_k)^{-1}, \quad (7)$$

$$P_{k|k} = (I - K_k H_k) P_{k|k-1} (I - K_k H_k)^T + K_k R_k K_k^T, \quad (8)$$

$$\hat{X}_{k|k} = \hat{X}_{k|k-1} + K_k e_k, \quad (9)$$

$$Q_k = (1 - dk) Q_{k-1} + dk (K_k e_k e_k^T K_k^T + P_{k|k} - \Phi_{k-1} P_{k-1|k-1} \Phi_{k-1}^T), \quad (10)$$

$$dk = (1 - b) / (1 - bk), \quad (11)$$

其中 Φ_k 是状态转移函数 f 的雅可比矩阵, $\Phi_k = \frac{\partial f(X_k)}{\partial X} \Big|_{X_k = X_{k|k}}$, $P_{k|k-1}$ 表示状态预测误差协方差矩阵, e_k 是创新量, H_k 是测量函数 h 的雅可比矩阵, $H_k = \frac{\partial h(X_k)}{\partial X} \Big|_{X_k = X_{k|k-1}}$, K_k 为卡尔曼增益, $P_{k|k}$ 表示估计误差协方差矩阵, b 为遗忘因子, 取值范围在0.95至0.99之间。

2.2. Sage-Husa算法的改进

(1) 更新过程噪声与测量噪声的统计特性

在滤波过程中, Q_k 必须是非负定的, 且 R_k 必须是正定的以抑制滤波器发散。然而, 方程 (10) 和 (6) 中 $-\Phi_{k-1} P_{k-1|k-1} \Phi_{k-1}^T$ 与 $-H_k P_{k|k-1} H_k^T$ 的存在并不能保证 Q_k 和 R_k 的正定性。为确保 Sage-Husa 算法的收敛性, 可放弃 $-\Phi_{k-1} P_{k-1|k-1} \Phi_{k-1}^T$ 与 $-H_k P_{k|k-1} H_k^T$, 如方程 (12) 和 (13) 所示 [42]。换言之, 该方法为保证滤波器的稳定性而牺牲了一定的滤波精度。

$$Q_k = (1 - dk) Q_{k-1} + dk (K_k e_k e_k^T K_k^T + P_{k|k}) \quad (12)$$

$$R_k = (1 - dk) R_{k-1} + dk (e_k e_k^T) \quad (13)$$

本文采用公式 (12) 更新 Q_k , 提出一种改进的 R_k 更新方法。先验残差 (亦称创新量) 的值与预测值相关, 如公式 (6) 所示; 后验残差则与状态估计值相关, 如公式 (14) 所示:

$$\delta_k = Z_k - h(\hat{X}_{k|k}). \quad (14)$$

使用误差传播定律计算后验残差的协方差, 如下所示 [43]:

$$E(\delta_k \delta_k^T) = R_k - H_k P_{k|k} H_k^T \quad (15)$$

$$R_k = E(\delta_k \delta_k^T) + H_k P_{k|k} H_k^T. \quad (16)$$

在实践中, 当前时刻 $\delta_k \delta_k^T$ 的值取代了 $\delta_k \delta_k^T$ 的期望。

方程 (6) 可改写为与后验残差相关的递归估计公式的另一种形式, 如下所示:

$$R_k = (1 - dk) R_{k-1} + dk R'_k, \quad (17)$$

其中 $R_k = \delta_k \delta_k^T + H_k P_{k|k} H_k^T$.

与公式(6)相比,可以看出该公式不包含减法部分,这保证了测量噪声协方差矩阵的正定性。

实际上,要计算 R' ,需要知道卡尔曼增益矩阵,但卡尔曼增益依赖于测量噪声协方差矩阵,陷入无限循环。为解决这一问题,需重新利用移动窗口对前序矩的均值。为简化计算流程,本文仅选取 $k-1$ 阶矩值。公式可表示为:

$$R_k = (1 - d_k)R_{k-1} + d_k(\delta_{k-1}\delta_{k-1}^T + H_{k-1}P_{k-1|k-1}H_{k-1}^T). \quad (18)$$

(2) 自适应双遗忘因子

遗忘因子在Sage-Husa算法的性能中起着关键作用,其固定值通常介于0.95至0.99之间。然而,这种固定值的遗忘因子难以适应系统变化。为使算法达到更优效果,遗忘因子应随系统变化而动态调整。传统Sage-Husa算法采用单一遗忘因子更新噪声统计特性,这种做法忽略了测量噪声协方差与过程噪声协方差之间的差异,即单一遗忘因子难以适应两种噪声协方差的更新。为此,本文提出了一种更新双遗忘因子的方法,如公式(19)所示:

$$b = \lambda_{\min} + (1 - \lambda_{\min}) * 2^L, \quad (19)$$

其中 $\lambda_{\min}$ 为遗忘因子的最小值,通常取为0.95, L 是与误差相关的变量。为自适应更新噪声统计特性,分别设置两个不同的遗忘因子来更新测量噪声协方差和过程噪声协方差。

测量噪声协方差通过与先验残差相关的遗忘因子进行更新;过程噪声协方差则通过与后验残差相关的遗忘因子进行更新。 L 的表达式(20)和(21)具有以下两种形式:

$$L_1 = -\frac{\sum_{i=k-S}^{k-1} e_i e_i^T}{S} \quad (20)$$

$$L_2 = -\frac{\sum_{i=k-S}^{k-1} \delta_i \delta_i^T}{S}, \quad (21)$$

其中 S 表示窗口宽度, k 表示当前时刻。从上述公式可以看出,该变量与窗口宽度和误差相关。在窗口宽度不变的前提下,遗忘因子的取值取决于先验残差和后验残差。上述两种自适应遗忘因子的获取方法,改变了传统Sage-Husa算法中固定的遗忘因子,使得自适应遗忘因子能够随状态变化而调整,从而更好地适应噪声统计特性的更新。

因此, R_k 和 Q_k 的修改如下:

$$R_k = (1 - d_1, k) R_{k-1} + d_1, k (\delta_{k-1} \delta_{k-1}^T + H_{k-1} P_{k-1|k-1} H_{k-1}^T) \quad (22)$$

$$Q_k = (1 - d_{2,k})Q_{k-1} + d_{2,k}(K_k e_k e_k^T K_k^T + P_{k|k}), \quad (23)$$

其中 $d_{1,k} = (1 - b_1) / (1 - b_{1,k})$, $b_1 = \lambda_{\min} + (1 - \lambda_{\min}) * 2^{L_1}$, $d_{2,k} = (1 - b_2) / (1 - b_{2,k})$, 且 $b_2 = \lambda_{\min} + (1 - \lambda_{\min}) * 2^{L_2}$ 。

(3) 用协方差匹配技术重新更新 R_k

随着迭代次数的增加, 累积误差会在一定程度上增大, 最终使用 Sage–Husa 滤波器的系统可能会出现发散现象。为避免这种情况, 本文提出将协方差匹配技术作为滤波发散的判定标准。具体而言, 在滤波过程中会持续检测实际创新值, 以判断其是否与理论值相符。协方差匹配技术以先验残差作为判断依据。本文采用该方法作为判断测量噪声是否需要重新更新的依据, 其决策依据如下公式所示:

$$e_k^T e_k \leq \text{tr}(H_k P_{k|k-1} H_k^T + R_k). \quad (24)$$

若公式 (24) 不成立, 则需重新更新测量噪声。Add a coefficient $\alpha_k = \frac{e_k^T e_k}{\text{tr}(H_k P_{k|k-1} H_k^T + R_k)}$ to Equation (18) as follows:

$$R_k = \alpha_k * [(1 - d_{1,k}) R_{k-1} + d_{1,k} (\delta_{k-1} \delta_{Tk-1}^T + H_{k-1} P_{k-1|k-1} H_{Tk-1}^T)]. \quad (25)$$

本文提出的方法可以实时更新测量噪声和过程噪声的统计特性, 保证测量噪声协方差矩阵为正定, 过程噪声协方差矩阵为非负定, 从而提高扩展卡尔曼滤波的精度。

(4) 算法的基本流程

改进的 Sage–Husa 算法在采样周期内的计算步骤如下:

- (1) 计算状态预测 $\hat{x}_{k|k-1} = f(\hat{x}_{k-1}, u_{k-1})$, 状态预测误差协方差矩阵 $P_{k|k-1} = \Phi_{k-1} P_{k-1|k-1} \Phi_{k-1}^T + Q_{k-1}$, 以及先验残差 $e_k = Z_k - h(\hat{x}_{k|k-1})$.
- (2) 使用先验残差获取自适应遗忘因子如下: $b_1 = \lambda_{\min} + (1 - \lambda_{\min}) * 2^{L_1}$, $L_1 = -\frac{\sum_{i=k-S}^{k-1} e_i e_i^T}{S}$.
- (3) 根据遗忘因子计算加权系数如下: $d_{1,k} = \frac{(1-b_1)}{(1-b_1^k)}$.
- (4) 更新测量噪声如下: $R_k = (1 - d_{1,k}) R_{k-1} + d_{1,k} (\delta_{k-1} \delta_{Tk-1}^T + H_{k-1} P_{k-1|k-1} H_{Tk-1}^T)$.
- (5) 根据先验残差和理论残差的大小, 若先验残差小于或等于理论残差, 则无需重新更新测量噪声; 否则, 测量噪声需按以下方式重新更新: $R_k = \alpha_k * [(1 - d_{1,k}) R_{k-1} + d_{1,k} (\delta_{k-1} \delta_{Tk-1}^T + H_{k-1} P_{k-1|k-1} H_{Tk-1}^T)]$.
- (6) 计算卡尔曼增益 $K_k = P_{k|k-1} H_k^T (H_k P_{k|k-1} H_k^T + R_k)^{-1}$, 估计误差协方差矩阵 $P_k = (I - K_k H_k) P_{k|k-1} (I - K_k H_k)^T + K_k R_k K_k^T$, 状态估计 $\hat{x}_k = \hat{x}_{k|k-1} + K_k e_k$, 以及后验残差 $\delta_k = Z_k - h(\hat{x}_k)$ 。

(7) 用后验残差更新第二个自适应遗忘因子，公式如下： $b_2 = \lambda_{\min} + (1 - \lambda_{\min})$

$$) * 2^{L_2}, L_2 = -\frac{\sum_{i=k-S}^{k-1} \delta_i \delta_i^T}{S}.$$

(8) 根据自适应遗忘因子计算加权系数follows: $d_{2,k} = \frac{(1-b_2)}{(1-b_2^k)}$.

(9) 更新过程噪声如下： $Q_k = (1 - d_2, k) Q_{k-1} + d_2, k (K_k e_k e_k^T + P_k/k)$ 。改进的Sage-Husa算法流程图如图1所示。




图1. 改进的Sage-Husa算法流程图。

3. 仿真与分析

为验证改进算法的有效性，本研究采用 EKF 算法、传统Sage-Husa算法及改进Sage-Husa算法，对经典案例示例1和示例2进行状态估计研究，并在传统算法中设置了不同遗忘因子值。

Sage-Husa算法。为便于表述本文提出的新算法，下文采用 AEKF 进行说明。

在仿真中，平均绝对误差（MAE）和均方根误差（RMSE）被用作比较标准，其定义如下：

$$MAE = \frac{1}{N} \sum_{k=1}^N |x_k - \hat{x}_k| \quad (26)$$

$$RMSE = \left[\frac{1}{N} \sum_{k=1}^N (x_k - \hat{x}_k)^2 \right]^{1/2}, \quad (27)$$

其中 N 表示数据样本的长度。

例1. 考虑以下一维非线性离散动态系统：

$$x_k = 0.5x_{k-1} + \frac{0.2x_{k-1}}{1 + x_{k-1}^2} + 8 \cos(1.2(k-1)) + W_{k-1} \quad (28)$$

$$z_k = \frac{x_k^2}{20} + V_k. \quad (29)$$

W_k 和 V_k 是独立的零均值高斯白噪声序列。对应的噪声统计量为 $Q=0.6$ 和 $R=0.15$ 。在仿真中，仿真时间为200秒，采样间隔为1秒，并进行了10次蒙特卡洛仿真，这意味着数据样本长度 $N=200$ ，噪声的统计特性未知或不准确，初始值被选为 $Q_0=0.06$ 和 $R_0=0.1$ 。假设系统状态的理论初始值为 $x_0=2$ 。误差协方差矩阵的初始值为 $P_0=0.01$ 。

针对示例1的仿真实验，我们分别采用 EKF 算法、Sage-Husa算法和 AEKF 算法进行模拟。如图2所示，通过设置Sage-Husa算法中不同的遗忘因子值，同步输出并比较了状态估计结果。为更直观地观察改进算法的性能，我们使用公式（26）和（27）计算了上述算法的平均绝对误差和均方根误差，并输出了对应图像，如图3和4所示。为得出普遍结论，我们对示例1进行了10次算法运行，记录每次运行的平均绝对误差和均方根误差，最终计算出10次实验结果的平均值，详见表1。




图2. 估计曲线。




图3 平均绝对误差曲线。




图4. 平均平方根误差曲线。

表1. 示例1中不同算法的平均绝对误差（MAE）与平均绝对误差（RMSE）对比。

时间	扩展卡尔曼滤波器		Sage-Husa ($b = 0.95$)		Sage-Husa ($b = 0.99$)		Sage-Husa ($b_1 = 0.95; b_2 = 0.99$)		AEKF	
	更多的	中误差	更多的	中误差	更多的	中误差	更多的	中误差	更多的	中误差
1	0.93	1.20	0.71	0.93	0.71	0.93	0.71	0.93	0.70	0.91
2	0.95	1.20	0.71	0.86	0.72	0.86	0.71	0.86	0.69	0.84
3	0.91	1.23	0.73	0.95	0.73	0.95	0.73	0.95	0.72	0.93
4	0.90	1.16	0.65	0.89	0.66	0.89	0.66	0.89	0.65	0.88
5	0.94	1.21	0.71	0.90	0.71	0.90	0.71	0.90	0.70	0.89
6	0.92	1.21	0.70	0.91	0.71	0.91	0.70	0.91	0.69	0.89
7	1.01	1.32	0.77	0.97	0.77	0.97	0.77	0.97	0.76	0.96
8	0.93	1.20	0.76	0.96	0.76	0.96	0.76	0.96	0.75	0.95
9	0.95	1.22	0.72	0.92	0.72	0.92	0.71	0.92	0.70	0.90
10	0.87	1.12	0.69	0.90	0.69	0.90	0.69	0.90	0.68	0.88
平均值	0.93	1.21	0.72	0.92	0.72	0.92	0.72	0.92	0.70	0.90

图2所示不同算法之间并无明显差异。然而如图3和4所示，各算法的MAE与 RMSE 曲线表明：在200次迭代内，EKF 算法的MAE和 RMSE 最大，而 AEKF 算法的MAE和 RMSE 最小。当遗忘因子取不同固定值时，其对Sage-Husa算法的影响可忽略不计。这一点可通过三种Sage-Husa算法的平均绝对误差与均方根误差之间的微小差异，以及三种算法的MAE与 RMSE 曲线均位于 EKF 和 AEKF 算法曲线之间得到证实。Sage-Husa算法的滤波精度优于 EKF 算法，但逊于 AEKF 算法。这表明该算法的估计

AEKF 算法的价值在于其最精确的计算结果,从而验证了 AEKF 算法的有效性。

如表1所示, EKF 算法的MAE和 RMSE 值最高,而三种Sage-Husa算法的平均绝对误差与均方根误差之间的差异相对较小。AEKF 算法的MAE和 RMSE 值均小于 EKF 算法和 Sage-Husa算法,并且在每次运行中保持稳定。这与图3和4中的曲线趋势一致,进一步证实了 AEKF 算法的有效性。

为了更清晰地观察自适应遗忘因子的变化,我们保存了两个自适应遗忘因子的输出图像,并将其与两个遗忘因子的固定值进行比较。图5和6分别展示了遗忘因子相对于先验残差和后验残差的变化曲线。




图5. 遗忘因子值b 1。




图6. 遗忘因子值b 2。

如图所示, AEKF 算法中使用的两个遗忘因子值被划分为两部分:位于窗口宽度内的值为0.95,其余部分的值在0.99附近波动,这证明 AEKF 算法中的自适应遗忘因子不仅能跟随系统变化,其值范围也保持在0.95至1之间。这既提升了滤波器的自适应性,又增强了其精度。

例2. 考虑以下多维非线性离散动态系统:

$$x_k = \begin{bmatrix} x_{1,k} \\ x_{2,k} \\ x_{3,k} \end{bmatrix} = \begin{bmatrix} 2 \cos(x_{2,k-1}) \\ x_{1,k-1} x_{2,k-1} \\ 0.4 x_{1,k-1} (x_{2,k-1} + x_{3,k-1}) \end{bmatrix} + W_{k-1} \quad (30)$$

$$z_k = x_{1,k} + x_{2,k} + x_{3,k} + V_k. \quad (31)$$

$W_k = [W_{1,k}, W_{2,k}, W_{3,k}]^T$ 和 V_k 是独立的零均值高斯白噪声序列。对应的噪声统计量为 $Q = \text{diag}[1.5, 1.5, 1.5]$, $R = 1.5$ 。在仿真中, 仿真时间为200秒, 采样间隔为1秒, 进行了10次蒙特卡洛仿真, 这意味着数据样本长度 $N = 200$, 噪声的统计特性未知或不准确, 初始值被选为 $Q_0 = \text{diag}[1, 1, 1]$ 和 $R_0 = 1$ 。假设系统的理论初始状态为 $x_0 = [0.2, 0.5, 0.2]^T$ 。误差协方差矩阵的初始值为 $P_0 = \text{diag}[1, 1, 1]$ 。

如示例2所示, 系统状态通过 EKF、Sage-Husa 和 AEKF 算法进行估计, 其中 Sage-Husa 算法配置了不同的固定遗忘因子。随后将这些算法与 AEKF 算法中的自适应遗忘因子进行对比, 以评估不同遗忘因子下各算法的估计精度。仿真实验表明, 针对该模型, Sage-Husa 算法在不同遗忘因子下的估计精度普遍较低, 且会出现随机发生的不同幅度跳跃 (参见图7和8)。这表明传统 Sage-Husa 算法 (无论是单遗忘因子还是双遗忘因子) 并不适用于多维模型。




图7. 传统Sage-Husa的估计值 $x_{1,k}$ 。




图8. 传统Sage-Husa的估计值 $x_{1,k}$ 。

基于上述分析, 通过评估状态估计值、均方绝对误差和均方根误差, 对 EKF 算法和 AEKF 算法的滤波性能进行了比较, 如图9-11所示。从图9可以看出, 当噪声的统计特性未知时, EKF 算法在滤波过程中会表现出估计值的随机跳跃。AEKF 在早期阶段就出现了跳跃现象。

在后续阶段保持稳定, 但过滤过程仍存在波动。图10和11显示, 所提出的 AEKF 算法生成的状态估计的平均绝对误差 (MAE) 和均方根误差 (RMSE) 始终小于传统 EKF 算法。虽然 AEKF 算法在模拟初期优势不明显, 但随着过滤过程的持续, 其精度会逐步提升。

为推广结论, 我们沿用示例1的相同方法, 重复进行了10次模拟实验。每次迭代的 MAE 和 RMSE 均被记录, 并计算平均值, 如表2所示。表2显示, AEKF 算法的 MAE 和 RMSE 在每次模拟中均低于 EKF 算法, 且其滤波精度较 EKF 有所提升。这不仅证实了 AEKF 算法比传统 EKF 具有更高精度, 还表明自适应遗忘因子相较于固定遗忘因子展现出更强的适应性。该机制解决了固定遗忘因子条件下的发散问题, 使状态估计更精确, 从而提升滤波精度。

为了更清楚地观察自适应遗忘因子的变化, 输出 AEKF 算法中两个自适应遗忘因子的曲线, 并与固定值遗忘因子进行比较。图12和13分别显示了与先验残差和后验残差相关的遗忘因子的变化曲线。




图9. EKF 和 AEKF 的估计值 x_1, k 。




图10. EKF 与 AEKF 的平均绝对误差 x_1, k 。




图11. EKF 与 AEKF 的均方根误差 x_1, k 。

表2 例2中不同算法的MAE与 RMSE 对比

乘以	扩展卡尔曼滤波		AEKF	
	更多的	中误差	更多的	中误差
1	2.52	3.53	2.22	2.91
2	2.37	3.60	2.20	2.90
3	2.46	3.60	2.33	3.00
4	2.28	3.47	2.24	2.94
5	2.41	3.52	2.16	2.88
6	2.41	3.60	2.23	2.82
7	2.44	3.50	2.28	2.84
8	2.29	3.62	2.09	3.08
9	2.32	3.55	2.27	3.00
10	2.23	3.58	2.10	2.88
平均值	2.37	3.56	2.21	2.93




图12。遗忘因子值 b_1 。




图13。遗忘因子值 b_2 。

从上图可以看出, 自适应遗忘因子的波动范围在0.95到1之间。与固定遗忘因子相比, 自适应遗忘因子能够根据残差的变化进行动态调整, 这验证了本文提出的指数形式遗忘因子更新方法的有效性。

通过对比 EKF 算法、不同遗忘因子的 Sage-Husa 算法以及示例1和2中的 AEKF 算法在状态估计中的表现, 可以明显看出 AEKF 算法展现出更强的稳定性, 其估计结果最接近真实值。仿真实验表明, 传统 Sage-Husa 算法存在发散现象, 这种现象在一维模型中表现较弱, 但在多维模型中则更为显著。深入分析发现, 其根本原因在于: EKF 算法假设噪声的统计特性恒定不变, 因此无法适应系统变化, 导致适应性不足。而采用固定遗忘因子 (无论是1还是2) 的 Sage-Husa 算法通过引入噪声统计量的更新机制, 有效解决了 EKF 中因未知噪声特性导致的滤波精度受限问题。但该算法的效果仍取决于遗忘因子的选择, 固定值遗忘因子本身缺乏自适应性。这种局限性可能导致噪声统计量更新过程中累积误差, 从而降低滤波精度甚至引发表散。相比之下, AEKF 算法采用指数更新机制来调整遗忘因子, 使其在保持0.95至1稳定范围的同时实现动态调节。此外, 该算法通过比较先验残差与理论残差的关系, 并依据特定标准判断是否需要重新更新测量噪声的统计特性。这种自适应机制能有效抑制累积误差, 使状态估计更接近真实值。因此, AEKF 算法不仅具备可行性, 更展现出卓越性能, 充分彰显其实用性和可靠性。

4. 结论

本文针对噪声统计特性未知时 EKF 算法存在滤波精度不足和发散问题的挑战展开研究, 这一缺陷限制了其在动态系统中的实际应用。通过在 Sage-Husa 算法基础上引入遗忘因子, 本研究提出关键创新以提升鲁棒性和适应性。具体而言, 所提方法在确保测量噪声协方差矩阵正定性及过程噪声协方差矩阵半正定性的前提下, 动态更新测量噪声与过程噪声的统计特性。通过比较先验残差与理论残差, 对测量噪声特性进行动态重估。此外, 引入采用窗口法与指数形式结合的自适应遗忘因子, 将遗忘因子范围维持在0.95至1之间, 从而增强算法稳定性。基于一维及多维状态变量的仿真结果表明, 所提出的 AEKF 算法具有显著优势。相较于标准 EKF 算法及采用不同遗忘因子的 Sage-Husa 算法, AEKF 算法在不同维度和条件下显著提升了滤波精度。这些改进不仅突破了传统 EKF 方法的局限, 更增强了该算法在噪声特性未知或动态变化的复杂实际场景中的实用价值。

作者贡献: 概念设计, W.L.; 方法学设计, W.L.; 软件开发, M.Z.; 验证工作, M.Z.; 形式分析, W.L.; 研究调查, W.L.; 资源调配, W.L.; 数据管理, M.Z.; 初稿撰写, W.L.; 审阅与编辑, M.Z. 和 H.F.; 项目监督, W.L.; 项目管理, W.L.; 经费筹措, H.F.。所有作者均已阅读并同意发表的文稿版本。

资助: 本研究由国家自然科学基金委员会资助, 项目编号: 51979210。

机构审查委员会声明: 不适用。

知情同意声明: 不适用。

数据可用性声明: 本文结论所依据的原始数据将由作者根据要求提供。

利益冲突: 作者声明无利益冲突。

参考文献

1. Minkler, G.; Minkler, J. *Kalman滤波的理论与应用*; Magellan Book Company: Palm Bay, FL, USA, 2002.
2. Victor, M.M.; Alberto, P. *Kalman滤波器的最新进展与应用*; IntechOpen: London, UK, 2011.
3. Widjiantoro, B.L.; Indriawati, K.; Buyung, T.S.N. A.; Wahyuadnyana, K.D. 实验验证: 基于扩展卡尔曼滤波算法的自动驾驶车辆感知与定位系统。 *国际智能传感与智能系统杂志* **2024**, *17*, 1–13. [[CrossRef](#)]
4. Wang, Z.; Liu, X.; Liu, Y. 基于扩展卡尔曼滤波的非线性动态基因调控网络建模方法——基于短基因表达时间序列。 *IEEE/ACM Trans. Comput. Biol. Bioinform.* **2009**, *6*, 410–419. [[交叉引用](#) [[PubMed](#)]]
5. Bemporad, A. 基于扩展卡尔曼滤波的凸损失与正则化函数的循环神经网络训练。 *IEEE 自动控制汇刊* **2023**, *68*, 5661–5668. [[交叉引用](#)]
6. 熊K、张H、陈C. 基于 UKF 的非线性滤波性能评估。 *Automatica* **2006**, *42*, 261–270. [[交叉引用](#)]
7. Turner, R.; Rasmussen, C.E. 基于模型的无香料卡尔曼滤波中sigma点的学习。 *神经计算* **2012**, *80*, 47–53. [[CrossRef](#)]
8. Hajiyeve, C.; Cilden-Guler, D. 基于SVD辅助自适应 UKF 处理不确定过程与测量噪声协方差的姿态滤波。 *国际鲁棒非线性控制期刊* **2023**, *33*, 10512–10531. [[交叉引用](#)]
9. Crisan, D.; Doucet, A. 颗粒滤波方法收敛性结果的实践者调查。 *IEEE 信号处理汇刊* **2002**, *50*, 736–746. [[交叉引用](#)]
10. Orchard, M.E.; Vachtsevanos, G.J. 一种用于在线故障诊断与失效预测的粒子滤波方法。 *测量与控制学会汇刊* **2009**, *31*, 221–246. [[交叉引用](#)]
11. Lahrech, A.; Soulhi, A. 基于粒子滤波的全球定位系统、里程计和地图数据融合在城市环境中的车辆定位。 *国际电气与计算机工程杂志* **2003**, *13*, 3924–3938. [[交叉引用](#)]
12. 库利科娃, M.V. 基于扩展协方差和组合平方根滤波器的最大似然估计。 *数学计算与模拟* **2009**, *79*, 1641–1657. [[交叉引用](#)]
13. 高斌; 胡国强; 李文; 赵勇; 钟勇. 基于最大似然的测量噪声协方差估计: 序贯二次规划在积分卡尔曼滤波中的应用——用于INS/BDS融合。 *数学问题与工程* **2021**, *2021*, 9383678. [[CrossRef](#)]
14. 林, C.L.; 张, Y.M.; 洪, C.C.; 杜, C.D.; 庄, C.Y. 基于模糊逻辑的自适应强跟踪卡尔曼滤波器在电容式触摸屏中的位置估计与平滑跟踪。 *工业电子。IEEE 工业电子汇刊* **2015**, *62*, 5097–5108. [[交叉引用](#)]
15. Ananthi, G. 电动汽车荷电状态估计: 改进的强跟踪卡尔曼滤波算法。 *Wirel. Pers. Commun.* **2023**, *128*, 147–160. [[交叉引用](#)]
16. Mukherjee, A.; Adhikari, P.P.; Nandi, P.K. 基于模糊逻辑的自适应卡尔曼滤波特征识别。 *Adv. Soft Comput. — AFSS* **2002**, *2275*, 163–170.
17. Zare, K.; Mardani, M.M.; Vafamand, N.; Khooban, M.H.; Sadr, S.S.; Dragievi, T. 基于模糊逻辑的主动悬架车辆系统自适应比例-积分滑模控制: 卡尔曼滤波方法。 *信息与控制技术* **2019**, *48*, 648–659. [[转载](#)]
18. Sage, A.P.; Husa, G.W. 未知先验统计量的自适应滤波。载于《联合自动控制会议论文集》, 美国科罗拉多州博尔德市, 1969年8月5–7日; 第760–769页。

19. Jiang, B.; Sheng, W.; Zhang, R.; Han, Y.; Ma, X. 基于自适应“电流”统计模型与速度预测的测距跟踪方法. *信号处理*. **2017**, *131*, 261–270. [\[交叉引用\]](#)
20. Wang, Y.; Meng, X.; Liu, J. 一种改进的自适应扩展卡尔曼滤波算法在SINS/GPS松耦合集成导航系统中的应用. *国际工程与技术杂志* **2018**, *7*, 87–91. [\[交叉引用\]](#)
21. 王, Q.; 张, M. 基于遗忘因子选择的Sage-Husa滤波器辅助的惯性导航系统陀螺在线校准. *海洋工程与技术杂志* **2018**, *21*, 1–8. [\[交叉引用\]](#)
22. 刘, K.; 赵, W.; 孙, B.; 吴, P.; 朱, D.; 张, P. 更新的鼠尾草-胡麻自适应卡尔曼滤波器在平移式喷灌机导航中的应用. *水* **2019**, *11*, 1269. [\[交叉引用\]](#)
23. 孙J、徐X、刘Y、张T、李Y. 基于改进AR模型和改进Sage-Husa自适应Kalman滤波器的雾随机漂移信号去噪方法. *传感器* **2016**, *16*, 1073. [\[交叉引用\]](#) [\[PubMed\]](#)
24. 范, Y.; 乔, S.; 王, G.; 陈, S.; 张, H. 一种改进的自适应卡尔曼滤波方法用于无人水面舰艇机动目标跟踪. *海洋工程* **2022**, *266*, 112890. [\[交叉引用\]](#)
25. 王, Z.; 刘, Z.; 田, K.; 张, H. 基于自适应Sage-Husa卡尔曼滤波器的动态测量频率扫描干涉技术. *光学激光工程* **2023**, *165*, 107545. [\[交叉引用\]](#)
26. 徐, S.; 周, H.; 王, J.; 何, Z.; 王, D. 基于改进的联邦Sage-Husa自适应滤波器的SINS/CNS/ GNSS 集成导航. *传感器* **2019**, *19*, 3812. [\[交叉引用\]](#)
27. 乔, S.; 范, Y.; 王, G.; 穆, D.; 何, Z. 基于平方根Sage-Husa自适应鲁棒卡尔曼滤波器的无人水面舰艇雷达目标跟踪. *传感器* **2022**, *22*, 2924. [\[交叉引用\]](#)
28. 魏伟、秦艳、张晓、张勇. Sage-Husa算法的改进. *中国惯性技术杂志* **2012**, *20*, 678–686.
29. 郭杰、何晨、李杰、魏浩. 基于改进Sage-Husa自适应卡尔曼滤波器的电动汽车坡度估计方法. *能源* **2022**, *15*, 4126. [\[交叉引用\]](#)
30. Xiang, L.; Cai, L.; Dai, N.; Gao, L.; Lei, G.; Li, J.; Deng, M. 基于改进的Sage-Husa扩展卡尔曼滤波算法的锂离子电池荷电状态估计. *世界电动汽车杂志* **2022**, *13*, 220. [\[交叉引用\]](#)
31. 朱, T.; 刘, Y.; 李, W.; 楼, J.; 朱, X. 基于改进Sage-Husa自适应滤波算法的SINS/ DVL An集成导航. *火控指挥控制* **2023**, *48*, 38–43.
32. 曾, Q.; 赵, T.; 赵, B.; 刘, J.; 朱, X. 基于指数衰减因子的自适应卡尔曼滤波算法在组合导航系统中的应用. *中国惯性技术杂志* **2021**, *29*, 307–313.
33. 段鹏、龚志、徐晓、赵晨. 改进的Sage-Husa算法用于实时轨迹滤波. *弹道学杂志* **2021**, *29*, 307–313.
34. Leung, S.H.; So, C.F. 基于梯度的变遗忘因子 RLS 算法在时变环境中的应用. *IEEE 信号处理汇刊* **2005**, *53*, 3141–3150. [\[交叉引用\]](#)
35. 王 H、郑 Y、余 Y. 基于自适应遗忘因子最小二乘在线辨识与无香卡尔曼滤波的锂离子电池状态估计. *数学* **2021**, *9*, 1733. [\[交叉引用\]](#)
36. 谢, W.; 赵, Y.; 方, Z.; 刘, S. 基于可变遗忘因子递归最小二乘法的超级电容电池模块等效电路模型参数辨识方法. *中国电气技术学会会刊* **2021**, *36*, 996–1005.
37. 范, X.; 冯, H.; 张, X. 最小二乘法的优化及其在锂离子电池模型参数辨识中的应用. *中国电气技术学会会刊* **2024**, *39*, 1577–1588.
38. 卢H、李G、张L. 基于动态遗忘因子递归最小二乘法与改进粒子滤波算法的锂电池SOC估计. *车载发动机* **2024**, *3*, 66–73.
39. Song, Q.; Mi, Y.; Lai, W. 一种新型可变遗忘因子递归最小二乘算法以提高电池模型参数辨识的抗干扰能力. *IEEE Access* **2019**, *7*, 61548–61557. [\[交叉引用\]](#)
40. 陈, Z.; 崔, W.; 崔, X.; 乔, H.; 卢, H.; 邱, N. 基于可变遗忘因子递归最小二乘算法的电动汽车绝缘检测新方法. *IEEE Access* **2021**, *9*, 73590–73607. [\[交叉引用\]](#)
41. Lao, Z.; Xia, B.; Wang, W.; Sun, W.; Lai, Y.; Wang, M. 基于可变遗忘因子递归最小二乘法的锂离子电池在线参数辨识新方法. *Energies* **2018**, *11*, 1358. [\[交叉引用\]](#)
42. 刘瑞、刘芳、刘晨、张鹏、费杰. 基于改进鼠尾草-胡麻自适应卡尔曼滤波器的SINS/ DVL 集成导航系统用于 AUV. *传感器杂志* **2021**, *1*, 9992041. [\[交叉引用\]](#)
43. 王, J. 实时运动GPS/格洛纳斯定位的随机建模. *导航* **1999**, *46*, 297–305. [\[交叉引用\]](#)

免责声明/出版商说明: 所有出版物中所含的陈述、观点和数据仅代表作者和贡献者个人, 而非 MDPI 和/或编辑。MDPI 和/或编辑不承担因内容中提及的任何观点、方法、说明或产品导致的人身伤害或财产损失的责任。